

Захист КП №1 — шпаргалка

Текст виступу (майже дослівно)

Вступ. «Тема комп'ютерного практикуму — перевірка генератора випадкових чисел на відповідність закону розподілу. Мета — навчитися будувати генератори випадкових величин із заданим законом і перевіряти їхню якість за критерієм згоди χ^2 -квадрат. Роботу виконано мовою Python із бібліотеками NumPy, SciPy та Matplotlib. Усі генератори випадкових величин я реалізував самостійно за формулами методички, а вбудований генератор random використовується лише як джерело рівномірно розподіленої величини дзета на інтервалі від нуля до одиниці.»

Завдання 1, запускаю task1_exponential.py. «Потрібно було згенерувати десять тисяч чисел за формулою: $\text{ікс} = \text{дорівнює} \text{мінус натуральний логарифм дзета, поділений на лямбда}$. Це метод оберненої функції: функція розподілу експоненційного закону дорівнює один мінус e в степені мінус лямбда ікс; прирівнюємо її до дзета, виражаємо ікс і отримуємо цю формулу. Перевірку зроблено при п'яти значеннях лямбда: нуль цілих п'ять десятих, один, два, п'ять і десять. Для кожної вибірки програма рахує середнє і дисперсію, будує гістограму частот на двадцяти інтервалах і перевіряє гіпотезу за критерієм χ^2 -квадрат.»

Результат завдання 1. «Середнє збігається з теоретичним один поділити на лямбда, дисперсія — з один поділити на лямбда у квадраті. Відношення сигми до середнього дорівнює приблизно одиниці — це характерна ознака експоненційного закону, бо для нього середнє дорівнює середньому квадратичному відхиленню. На цій підставі я висунув гіпотезу про експоненційний закон, оцінив параметр як лямбда дорівнює одиниця поділити на середнє і перевіряв гіпотезу. При всіх лямбда χ^2 -квадрат менший за критичне значення, тобто гіпотеза приймається з довірчою ймовірністю нуль цілих дев'яносто п'ять сотих. Ось гістограма для лямбда дорівнює одиниці: стовпчики монотонно спадають, а червона крива — теоретична щільність, помножена на кількість чисел і на ширину інтервалу.»

Завдання 2, запускаю task1_lcg.py. «Другий генератор — мультиплікативний конгруентний: зет наступне дорівнює а помножити на зет попереднє за модулем m , а саме випадкове число — це зет поділити на m . Базові параметри із завдання: а дорівнює п'ять у тринадцятому степені, це дорівнює два у тридцять першому. Додатково я дослідив ще п'ять наборів параметрів: відомий генератор Парка–Міллера, генератор RANDU та три свідомо погані варіанти. Для кожного набору програма рахує середнє, дисперсію, довжину періоду і перевіряє рівномірність на інтервалі від нуля до одиниці за критерієм χ^2 -квадрат.»

Результат завдання 2. «Базовий набір: середнє нуль цілих п'ять тисяч сорок одна, дисперсія нуль цілих вісімсот тридцять дев'ять десятих тисячних, тобто близько до теоретичних нуль цілих п'ять і одна дванадцята. χ^2 -квадрат двадцять один і сім десятих менший за критичне тридцять і чотирнадцять сотих, тому гіпотезу про рівномірний закон прийнято. Період перевищує два мільйони; теоретично для непарного початкового значення він дорівнює два у двадцять дев'ятому степені. Тепер погані набори. При c дорівнює два у восьмому степені період становить лише шістьдесят чотири значення, послідовність швидко повторюється, і χ^2 -квадрат сто п'ятдесят шість відхиляє гіпотезу. При парному множнику два в десятому порушується умова а дорівнює один плюс чотири ка, і послідовність за кілька кроків вироджується в нуль. Окремо зверну увагу на випадок c дорівнює два у дванадцятому: там χ^2 -квадрат майже нульовий, нуль цілих дев'яносто сім сотих. Це не ознака якості, а навпаки: частоти надто рівні для випадкової вибірки, бо період усього тисяча двадцять чотири і значення повторились майже десять разів.»

Акцент: показую task1_lcg_3_pairs.png. «Найцікавіший приклад — генератор RANDU із множником шістьдесят п'ять тисяч п'ятсот тридцять дев'ять. За критерієм χ^2 -квадрат він успішно проходить перевірку на рівномірність. Але якщо побудувати трійки послідовних чисел в одиничному кубі, видно, що всі точки лежать на п'ятнадцяти паралельних площинах. Причина в тому, що вираз $9a^3$ дзета і мінус шість дзета і плюс перше плюс дзета і плюс друге завжди дає ціле число. Звідси висновок: одного критерію χ^2 -квадрат недостатньо, генератор треба перевіряти також на період, незалежність і багатовимірну рівномірність.»

Завдання 3, запускаю task2_sort_timing.py. «Третє завдання — дослідити часову затримку програми на сортування колекції з мільйона об'єктів. Я створив список із мільйона об'єктів класу Item, перед кожним запуском перемішував його і вимірював час роботи методу sort; перемішування в замір не входить. Перші десять запусків розігрівні й відкидаються, далі виконано п'ятсот вимірювань, які збережено у файл, щоб результат був відтворюваним.»

Результат завдання 3. «Середній час — п'ятсот сорок чотири і вісім десятих мілісекунди, середнє квадратичне відхилення — п'ятдесят сім і три десятих, мінімум — близько чотиреста вісімдесят сім. Відношення сигми до середнього дорівнює нуль цілих асоти п'ять тисячних, тому експоненційний закон відпадає одразу: для нього це відношення дорівнює одиниці. Коефіцієнт асиметрії два і три десятих, тобто розподіл має правий хвіст, а мінімальне значення — це чистий час роботи алгоритму. Тому перевірялися також закони зі зсувом. Усього перевірено шість гіпотез: рівномірний, нормальний, експоненційний, Ерланга, логнормальний і логнормальний зі зсувом. Жодна з них за критерієм χ^2 -квадрат не прийнята. Причину видно на графіку послідовності вимірювань: приблизно з двісті п'ятого по двісті шістьдесятий запуск система працювала повільніше, шістьсот п'ятдесят — сімсот мілісекунд проти п'ятисот двадцяти. Отже, вибірка є сумішшю двох режимів роботи системи, і стандартний закон її не описує. Найближче наближення дає логнормальний закон зі зсувом.»

Імітаційні генератори. «Далі я побудував два генератори, що імітують затримку. Перший параметричний — логнормальний зі зсувом, де нормальна складова отримана методом полярних координат Марсальї–Брея. Другий — табличний, за емпіричною функцією розподілу вимірних даних. Порівняння показало таке: логнормальний генератор відтворює середнє з похибкою нуль цілих одна десята відсотка і сигму з похибкою близько п'яти відсотків, але форму розподілу не відтворює — χ^2 -квадрат однорідності дев'яносто вісім при критичному шістнадцять і дев'яносто дві сотих, і критерій Колмогорова–Смірнова також відхиляє однорідність. Табличний генератор відтворює розподіл точно: χ^2 -квадрат однорідності нуль цілих дев'янадцять сотих, квантили збігаються з вимірними.»

Висновок. «Метод оберненої функції на основі вбудованого рівномірного генератора коректно відтворює експоненційний закон при всіх значеннях параметра. Конгруентний генератор придатний для імітаційного моделювання лише з правильно підібраними параметрами: інакше маємо короткий період або виродження послідовності, причому критерій χ^2 -квадрат сам по собі якості генератора не гарантує. Затримка реальної програми не описується жодним стандартним законом, оскільки залежить від стану обчислювальної системи; для її імітації найточніше підходить табличний метод за емпіричною функцією розподілу. Доповідь завершено, готовий відповісти на запитання.»

Порядок показу (5–7 хв)

1. Мета: побудувати генератори з заданим законом і перевірити їх за критерієм χ^2 . Python; генератори написані вручну, вбудований random — лише джерело $\zeta \sim U(0;1)$.
2. Запуск task1_exponential.py (2 с). Показати: $\mu \approx 1/\lambda$, $\sigma/\mu \approx 1$, $\chi^2 < \chi^2_{кр}$ для всіх λ . Відкрити task1_exp_lambda_1.0.png.
3. Запуск task1_lcg.py (5 с). Показати таблицю 2 зі звіту: базові $a = 5^{13}$, $c = 2^{31}$ — рівномірний; $a = 5$, $c = 2^8$ — період 64, $\chi^2 = 156,27$; $a = 2^{10}$ — вироджується в 0.
4. Головний акцент: task1_lcg_3_pairs.png (RANDU). Проходить χ^2 , але всі трійки лежать на 15 площинах, бо $9\zeta_i - 6\zeta_{i+1} + \zeta_{i+2}$ завжди ціле $\rightarrow$ одного χ^2 замало.

- Запуск task2_sort_timing.py (2 с, бере збережені 500 вимірювань). Показати task2_series.png: ряд нестационарний, тому жодна гіпотеза не прийнята. Далі таблицю 3: табличний генератор $\chi^2 = 0,19 < 16,92$.
- Висновок: метод оберненої функції коректно дає експоненційний закон; конгруентний генератор придатний лише з правильними параметрами; затримку реальної програми найточніше відтворює табличний метод.

Ключові цифри

Завдання 1. $N = 10000$, 20 інтервалів, $\alpha = 0,05$. $\lambda = 0,5$: $\mu \sim 1,9702$, $\sigma^2 \sim 4,0052$, $\chi^2 = 8,39 < 21,03$. $\lambda = 1$: $\chi^2 = 18,85 < 21,03$. $\lambda = 2$: $14,68 < 25,00$. $\lambda = 5$: $10,98 < 25,00$. $\lambda = 10$: $11,54 < 23,68$. Усі гіпотези приймаються.

Завдання 2. $\chi^2_{кр} = 30,14$ ($df = 19$). $5^{13}/2^{31}$: $\chi^2 = 21,69$, $\mu \sim 0,5041$, $\sigma^2 \sim 0,0839$, період $> 2 \cdot 10^6$ (теор. 2^{29}). $16807/2^{31}-1$: 12,70. RANDU: 15,16. $5^{13}/2^{12}$: 0,97, період 1024. $5/2^8$: 156,27, період 64. $2^{10}/2^{31}$: 189960.

Завдання 3. $n = 500$ вимірювань, $\mu \sim 544,8$ мс, $\sigma \sim 57,3$ мс, $\sigma/\mu = 0,105$, асиметрія 2,29, $\min \approx 487$ мс. Жодна з 6 гіпотез не прийнята; найближча — логнормальний зі зсувом ($\chi^2 = 141,22$ при $\chi^2_{кр} = 12,59$). Точність: логнормальний — похибка $\mu 0,1\%$, χ^2 однорідності 98,17; табличний — 0,2%, $\chi^2 = 0,19 < 16,92$, KS $p = 1,00$.

Часті питання

Чому різні df (12, 15, 14)? Інтервали з $n \cdot p_i < 5$ об'єднуються, тому груп менше 20; ще мінус 1 за параметр λ , оцінений за вибіркою: $df = k - 1 - 1$.

Чому $\chi^2 = 0,97$ — це погано? $p \approx 1$ означає «надто рівні» частоти для випадкової вибірки. Це ознака короткого періоду (1024 значення повторились ~ 10 разів).

Чому RANDU поганий, якщо χ^2 пройшов? χ^2 перевіряє лише рівномірність окремих значень. Трійки лежать на 15 площинах — порушена багатовимірна рівномірність.

Чому при $a = 2^{10}$ усе вироджується? Порушено умову $a = 1 + 4k$: множник парний, молодші розряди обнуляються, за кілька кроків $z = 0$.

Навіщо z_0 непарне? Умова максимального періоду 2^{B-2} при $c = 2^B$.

Чому закон затримки не експоненційний? Для експоненційного $\sigma/\mu = 1$, у нас 0,105; є нижня межа ≈ 490 мс — чистий час алгоритму, тому потрібні закони зі зсувом.

Чому жодна гіпотеза не прийнята? Ряд нестационарний: приблизно з 205-го по 260-й запуск система працювала повільніше (650–700 мс проти 520 мс). Вибірка — суміш двох режимів.

Чому не pr.random.normal? За методичкою потрібні методи генерування: нормальна складова — метод Марсальї–Брея, Ерланга — сума k експоненційних, емпіричний закон — табличний метод.

Що означає «гіпотеза приймається»? Дані не суперечать закону з довірчою ймовірністю 0,95. Це не доведення: з ймовірністю 0,05 узгодження випадкове.

Формули, якщо питають

Обернена функція: $\zeta = F(r) \sim U(0;1) \rightarrow r = F^{-1}(\zeta)$; експоненційний: $x = -\ln(\zeta)/\lambda$.

Конгруентний: $z_{i+1} = a \cdot z_i \pmod{c}$, $\zeta = z/c$; $c = 2^B \rightarrow \text{mod} = \text{відкидання старших розрядів}$.

Марсальї–Брея: $\alpha_i = 2\zeta_i - 1$; якщо $s = \alpha_i^2 + \alpha_{i+1}^2 \leq 1$, то $\gamma_i = \alpha_i \cdot \sqrt{(-2 \ln s / s)}$; $x = a + \sigma \cdot \gamma$.

Табличний: $r = x_{i-1} + (x_i - x_{i-1})(\zeta - a_{i-1})/(a_i - a_{i-1})$.

Критерій: $\chi^2 = \sum (n_i - n \cdot p_i)^2 / (n \cdot p_i)$, $df = k - 1 - r$, $\alpha = 0,05$; $n \geq 100$, $n_i \geq 5$. Для $n < 100$ — критерій Колмогорова–Смірнова: $\lambda = \max |w_i - w_i^T| \cdot \sqrt{n} < 1,36$.

Чого не робити

- Не видаляти output/sort_times.csv і не перезаміряти під час захисту: це 8 хв і інші цифри, ніж у звіті.
- Не чекати вікон з графіками — вони зберігаються у output/*.png, показувати звідти.
- Не казати «дані нормальні»: у завданні 3 жодна гіпотеза не прийнята, і це свідомий результат.
- Перед показом закрити зайві програми, щоб не спотворити час сортування.